MATEMATICKO-FYZIKÁLNÍ FAKULTA
Univerzita Karlova

DIPLOMOVÁ PRÁCE

Bc. Eliška Povolná

Vysvětlitelné a upravitelné doporučování volnočasových aktivit

Katedra softwarového inženýrství

Vedoucí diplomové práce: Mgr. Ladislav Peška, Ph.D.
Studijní program: Softwarové a datové inženýrství

Praha 2025

Prohlašuji, že jsem tuto diplomovou práci vypracoval(a) samostatně a výhradně s použitím citovaných pramenů, literatury a dalších odborných zdrojů. Beru na vědomí, že se na moji práci vztahují práva a povinnosti vyplývající ze zákona č. 121/2000 Sb., autorského zákona v platném znění, zejména skutečnost, že Univerzita Karlova má právo na uzavření licenční smlouvy o užití této práce jako školního díla podle §60 odst. 1 autorského zákona.

V ..... dne ....

Podpis autora

Poděkování.

Název práce: Vysvětlitelné a upravitelné doporučování volnočasových aktivit

Autor: Bc. Eliška Povolná

Katedra: Katedra softwarového inženýrství

Vedoucí diplomové práce: Mgr. Ladislav Peška, Ph.D., katedra softwarového inženýrství

Abstrakt: Abstrakt.

Klíčová slova: doporučovací systémy, sparse autoencoders, POI

Title: Explainable and Steerable POI Recommendations

Author: Bc. Eliška Povolná

Department: Department of software engineering

Supervisor: Mgr. Ladislav Peška, Ph.D., department of software engineering

Abstract: Abstract.

Keywords: recommender systems, sparse autoencoders, POI

Obsah

1 Teoretické základy a terminologie **9**
1.1 Doporučovací systémy a doména POI 9
1.1.1 Základní přístupy k doporučování 9
1.1.2 Specifika doporučování bodů zájmu (POI) 10
1.2 Latentní reprezentace a architektura autoenkodérů 11
1.2.1 Autoenkodéry pro kolaborativní filtrování (CFAE) 11
1.2.2 Řídké autoenkodéry (SAE) 12
1.2.3 Interpretace a ovládací prvky (Knobs) 12
1.3 Vysvětlitelnost a interaktivní řízení (Steering) 13
1.3.1 Vysvětlitelnost doporučení a její hodnocení 13
1.3.2 Steering: Definice a pohledy na ovladatelnost 13
1.3.3 Etické, právní a kognitivní aspekty interakce 14
1.4 Shrnutí 15

2 Související práce **17**
2.1 Explainable recommendation systems 17
2.1.1 Model-based explainability 17
2.1.2 Post-hoc explainability 17
2.2 Disentangled representations 18
2.2.1 VAE a další přístupy 18
2.2.2 From Knots to Knobs a řídké autoenkodéry 18
2.2.3 Sémantické mapování pomocí LLM (Autointerpretability) 18
2.3 Interaktivní a ovladatelné recommender systémy 18
2.3.1 TasteWeights a příbuzné koncepty 19
2.3.2 User-controllable personalization 19
2.4 Doporučování POI 19
2.4.1 Časoprostorové a sekvenční modely 19
2.4.2 Řešení sémantické řídkosti pomocí LLM (Pseudo-profily) . 19
2.5 Shrnutí 20

3 Návrh řešení **21**
3.1 Cíle a výzkumné otázky 21
3.2 Architektura navrženého systému 21
3.2.1 Modelování kolaborativního filtrování (CFAE) 21
3.2.2 Sparse autoencoder pro interpretovatelné preference 22
3.3 Vysvětlitelnost modelu 22
3.3.1 Sémantické mapování (Labeling) řídkých faktorů 22
3.3.2 Generování vysvětlení 23
3.4 Ovládání a úprava preferencí (Steering) 23
3.4.1 Matematický model steeringu 23
3.4.2 Aktualizace doporučení 23
3.5 Očekávané přínosy 23

4 Implementace [draft] **25**
4.1 Použité technologie a knihovny 25
4.2 Předzpracování a reprezentace dat 26
4.3 Implementace modelu 26
4.4 Systém vysvětlování a úprav 27
4.5 Uživatelské rozhraní 27

Seznam použitých zkratek **28**

A Přílohy **29**
A.1 První příloha 29

Úvod

Současné doporučovací systémy dosahují vysoké přesnosti díky komplexním latentním reprezentacím, které jsou však často neprůhledné a obtížně ovladatelné. Cílem této práce je využít řídké autoenkodéry (*sparse autoencoders*) integrované do architektury kolaborativního filtrování k transformaci latentních vektorů na interpretovatelné a uživatelsky ovlivnitelné reprezentace preferencí v doméně volnočasových aktivit (tzv. *points of interest*, POIs). Práce navazuje na aktuálně recenzovaný článek vedoucího práce [1] a adaptuje jeho výsledky do cílové domény doporučování míst.

Tento přístup reaguje na fundamentální problém moderních doporučovacích systémů. Přestože hluboké modely a maticové faktorizace přinášejí vynikající prediktivní přesnost, během trénování vytvářejí husté, propletené (*entangled*) reprezentace, jež fungují jako tzv. černé skříňky (*black-boxes*). Neprůhlednost těchto latentních reprezentací představuje zásadní překážku – uživatelé nerozumí tomu, proč jim jsou konkrétní položky nabízeny, a vývojáři mají omezené možnosti odhalit interní mechanismy algoritmu [2]. Tento nedostatek transparentnosti nejenže snižuje celkovou důvěru v systém [3], ale především omezuje uživatelskou ovladatelnost. Pokud uživatel nechápe profil, který si o něm systém vytvořil, nemá ani možnost jeho nepřesnosti korigovat a směřovat tak další doporučení správným směrem [4].

Motivace a cíl práce

V kontextu doporučování bodů zájmu (POI) je absence transparentnosti a interaktivity ještě kritičtější než v tradičních doménách (jako jsou e-shopy či streamovací platformy pro filmy). Preference v oblasti volnočasových aktivit jsou totiž silně vázány na geografické a časoprostorové faktory [5], jako je fyzická vzdálenost, dostupnost či aktuální situace uživatele. Uživatelské záměry se v této doméně mění velice dynamicky. Běžné doporučovací modely nedokážou tento složitý kontext uživateli dostatečně srozumitelně zprostředkovat a neposkytují mu nástroje pro snadnou interaktivní úpravu v reálném čase.

Cílem této práce je proto vytvořit model využívající řídké autoenkodéry (SAE) pro extrakci vysvětlitelných a upravitelných preferencí. Začleněním mechanismu řídkosti (sparsity) do procesu kolaborativního filtrování se model naučí transformovat abstraktní doporučovací faktory do sémanticky pochopitelné podoby. Tyto extrahované rysy pak poslouží nejen jako základ pro generování textových či vizuálních vysvětlení, ale především jako interaktivní "ovládací prvky"(*knobs*), skrze které může uživatel své preference přímo řídit a upravovat.

Přínos práce

Hlavní přínos předkládané diplomové práce spočívá v inovativní syntéze pokročilých přístupů z oblasti interpretability do specifické domény doporučování bodů zájmu (POI). Tradiční modely kolaborativního filtrování sice dosahují vysoké přesnosti, ale vytvářejí neprůhledné latentní reprezentace, což je v doméně POI –

navíc často zatížené extrémní řídkostí dat a nedostatkem detailních sémantických informací – zásadní překážka. Práce na tento stav reaguje návrhem architektury, která navazuje na moderní koncepty rozpletených (*disentangled*) reprezentací [6] a využívá řídké autoenkodéry (SAE) [1] k transformaci komplexních uživatelských preferencí do izolovaných rysů. K překonání absence sémantiky v lokačních datech je nově navržena integrace velkých jazykových modelů (LLM), které z historie návštěv uživatele automaticky extrahují tzv. pseudo-profily [5] a přiřazují abstraktním neuronům lidsky pochopitelný význam.

Na tuto transformaci latentního prostoru plynule navazuje mechanismus vysvětlitelnosti, jenž s využitím myšlenek z modelů jako *ReEL (Review-Aware Explanation of Location Recommendation)* [7] propojuje extrahované faktory s konkrétními tagy a aspekty míst (např. atmosféra, vhodnost pro děti, kvalita služeb). Tím vzniká exaktní základ pro generování personalizovaných vysvětlení. Systém však nezůstává pouze u pasivního vysvětlování. Inspirací z interaktivních nástrojů typu *TasteWeights* [8] práce navrhuje mechanismus přímého řízení (*steering*), jímž uživatelé získávají možnost do svých vygenerovaných profilů aktivně zasáhnout. Zviditelnění těchto ovládacích prvků vrací uživatelům nad systémem kontrolu (tzv. *agency*), což dle stávajících výzkumů pomáhá vyvažovat obavy ze ztráty soukromí spojené s profilováním [9]. Jak navíc dokazují nedávné studie [4], právě tento přechod od *black-box* doporučení k ovladatelné interakci – za předpokladu, že uživatel přímo vidí okamžitý dopad svých úprav – má prokazatelně signifikantní vliv na budování uživatelské důvěry (trust) a vnímané transparentnosti celého doporučovacího procesu.

Struktura práce

Text této diplomové práce je logicky členěn do pěti hlavních kapitol. První kapitola definuje formální a matematický rámec doporučovacích systémů. Představuje architekturu autoenkodérů, principy vynucování řídkosti u skrytých reprezentací a teoreticky ukotvuje pojmy vysvětlitelnosti a interaktivního řízení preferencí (steering). Na tyto základy navazuje druhá kapitola, jež podává ucelenou rešerši současného stavu poznání. Mapuje existující přístupy k vysvětlitelnosti, metody pro rozpletení latentních prostorů (disentanglement) a aktuální trendy ve využívání velkých jazykových modelů v doporučování.

Třetí kapitola následně představuje samotný architektonický návrh systému. Jsou zde definovány výzkumné otázky a je detailně popsána celá navrhovaná pipeline – od kolaborativního filtrování přes automatické sémantické pojmenovávání extrahovaných neuronů pomocí LLM až po logiku uživatelského rozhraní. Praktické realizaci tohoto návrhu je věnována čtvrtá kapitola. Ta popisuje využité datové sady Yelp, kroky předzpracování, implementačními detaily doporučovacího modelu a fungováním webové aplikace vytvořené pro uživatelské testování. V páté kapitole jsou poté shrnuty a analyzovány dosažené výsledky. Prezentovány jsou nejen objektivní metriky přesnosti na historických datech, ale především detailní vyhodnocení uživatelské studie zaměřené na to, jak koncoví uživatelé vnímají transparentnost a ovladatelnost systému. Závěr práce rekapituluje dosažené výsledky vzhledem k vytyčeným cílům, objektivně diskutuje limity navrženého řešení a nastiňuje možné směry pro budoucí výzkum.

1 Teoretické základy a terminologie

Tato kapitola představuje základní pojmy a teoretická východiska, o která se opírá návrh vysvětlitelného a ovladatelného doporučovacího systému. Nejprve jsou představeny tradiční i moderní přístupy k doporučování, včetně jejich matematické formalizace. Následně je rozebrán koncept řídkých autoenkodérů (SAE) a specifika domény bodů zájmu (POI). V závěru jsou definovány principy vysvětlitelnosti a interaktivního řízení preferencí (steering).

1.1 Doporučovací systémy a doména POI

Doporučovací systémy (*Recommender Systems*, RS) jsou softwarové aplikace určené k personalizovanému navrhování položek či aktivit na základě preferencí, chování a kontextu uživatele [10]. Jejich cílem je pomoci uživateli zorientovat se v množství dostupných možností a zvýšit pravděpodobnost, že si vybere relevantní položku.

1.1.1 Základní přístupy k doporučování

Podle standardní oborové taxonomie, kterou definoval Burke [11] a ve svém přehledu shrnují Ricci a kol. [10], lze doporučovací systémy rozdělit do několika kategorií podle toho, s jakými daty pracují. Z hlediska historického vývoje i současné praxe se nejčastěji setkáváme se třemi hlavními přístupy:

- **Kolaborativní filtrování (CF):** Tento přístup staví výhradně na historii interakcí mezi uživateli a položkami. Předpokládá, že uživatelé se stejným chováním v minulosti (např. navštěvující stejné typy restaurací) budou mít podobný vkus i v budoucnu [10]. Ačkoliv jde o vysoce účinnou metodu, naráží na kritický problém tzv. *studeného startu* (cold start). Ten nastává v okamžiku, kdy do systému přibude zcela nový uživatel či nová položka bez jakékoliv historie interakcí. Bez historických dat nedokáže CF najít relevantní podobnosti a selhává.

- **Obsahové filtrování (CBF):** Tento model naopak porovnává vnitřní vlastnosti (metadata) samotných položek s uživatelským profilem [11]. V kontextu doporučování bodů zájmu (POI) může jít o textové popisy lokací, přiřazené tagy či kategorie (např. italská kuchyně, bezbariérový přístup). Protože k hodnocení nevyžaduje data od ostatních uživatelů, je CBF přirozeně odolné vůči problému studeného startu u nových položek. Hrozí u něj ovšem tzv. *přespecifikování* (overspecialization), kdy systém uživateli nabízí pouze položky velmi podobné těm, které již zná, a ztrácí schopnost objevovat pro něj nové koncepty.

- **Hybridní přístupy:** Tyto metody cíleně kombinují výhody obou předchozích světů [11, 10]. Využitím obsahových rysů k obohacení řídkých kolaborativních dat dokáží elegantně překonat úskalí studeného startu, a zároveň

si díky kolaborativní složce zachovávají schopnost objevovat pro uživatele nové a často nečekané okruhy zájmů.

Abychom v následujících kapitolách mohli přesně popsat, jakým způsobem náš navrhovaný systém tyto přístupy kombinuje, je nezbytné si nejprve ukázat, jak jsou v doporučovacích systémech data a cíle reprezentovány matematicky. Ačkoliv se totiž výše uvedené metody liší v tom, jaké informace zpracovávají, všechny sdílejí stejný fundamentální úkol: odhadnout neznámou míru preference konkrétního uživatele k dané položce.

Nechť $U = \{u_1, u_2, \ldots, u_{|U|}\}$ je množina všech uživatelů a $I = \{i_1, i_2, \ldots, i_{|I|}\}$ je množina všech dostupných položek. Historie pozorovaných interakcí je v základním pojetí zachycena pomocí matice $\mathbf{X} \in \mathbb{R}^{|U| \times |I|}$, kde prvek $x_{u,i}$ nabývá konkrétní hodnoty v případě, že mezi uživatelem a položkou proběhla interakce (např. hodnota 1 pro navštívené místo, 0 jinak).

Cílem doporučovacího systému je naučit se predikční funkci f, která pro libovolný pár uživatel-položka odhadne chybějící relevanci (tzv. skóre) jako $\hat{x}_{u,i} = f(u, i \mid \Theta)$, kde Θ představuje natrénované parametry modelu. Uvedené tři přístupy se pak formálně liší právě v tom, z čeho se tato funkce učí. Zatímco u čistého kolaborativního filtrování se parametry Θ optimalizují výhradně ze vztahů uvnitř matice interakcí $\mathbf{X}$, v případě obsahových a hybridních metod zohledňuje funkce f i dodatečné vektory vlastností (metadat) samotných položek. Právě to umožňuje modelu matematicky vyčíslit skóre $\hat{x}_{u,i}$ i pro položku s prázdnou historií interakcí, čímž je formálně překonán onen zmíněný problém studeného startu.

1.1.2 Specifika doporučování bodů zájmu (POI)

Doporučování bodů zájmu (*Points of Interest*, POI) představuje specifickou podoblast doporučovacích úloh. Na rozdíl od tradičních platforem pro elektronický obchod (kde si uživatel produkt pouze koupí a nechá doručit) je výběr volnočasových aktivit silně ovlivněn fyzickým a situačním kontextem. Mezi nejvýznamnější omezující faktory patří:

- **Geografická poloha:** Doporučení je pro uživatele relevantní pouze tehdy, nachází-li se místo v jeho fyzické dostupnosti a vzdálenosti, kterou je ochoten překonat.
- **Časové a situační podmínky:** Dostupnost lokace je vázána na otevírací dobu, přičemž vhodnost doporučení může dramaticky měnit i počasí nebo účel cesty (např. oběd s rodinou vs. večerní posezení s přáteli).

V současném výzkumu se k těmto lokačním datům přistupuje dvěma hlavními způsoby. Prvním z nich je modelování problému jako uspořádané sekvence návštěv (tzv. *Next-POI recommendation*). Zde se předpokládá, že interakce uživatele u tvoří časovou řadu $S_u = \{(i_1, t_1), (i_2, t_2), \ldots, (i_n, t_n)\}$, a systém se snaží odhadnout bezprostředně následující krok s ohledem na časové rozestupy a překonanou vzdálenost [5].

Ačkoliv jsou sekvenční modely vysoce efektivní pro predikci tras v reálném čase, pro hlubší porozumění zájmům uživatele (např. při dlouhodobém plánování dovolené) bývá vhodnější **druhý přístup, založený na ne-sekvenčním**

modelování preferencí [12, 13]. Ten abstrahuje od striktní časové návaznosti a nahlíží na problém skrze celkovou matici historických interakcí (typicky s využitím maticové faktorizace či kolaborativního filtrování). Systém tak dokáže vytvořit komplexní profil uživatele (např. "má rád italskou kuchyni a historické památky"), který je stabilnější v čase. Tento přístup je ústředním prvkem i pro námi navrhovanou architekturu, u níž jsou pro zachycení zájmů primárně využívány metody hlubokého kolaborativního filtrování nad statickou maticí interakcí.

Bez ohledu na zvolenou metodu modelování je však v doméně POI důležitá **vysvětlitelnost a transparentnost**. Zatímco u digitálního obsahu (např. u filmů či hudby) lze špatné doporučení snadno přeskočit, návštěva fyzické lokace vyžaduje od uživatele investici času a často i peněz. Proto je pro budování důvěry nezbytné, aby systém dokázal svá rozhodnutí přesvědčivě a srozumitelně zdůvodnit. Lokační data navíc představují specifický problém v tom, že v sobě přirozeně mísí (tzv. *entanglují*) zcela odlišné motivace. Jak upozorňují Zeng a kol. [5], check-in chování je silně ovlivněno prostorovými a časovými faktory, které se v datech složitě prolínají se skutečnými sémantickými zájmy uživatele. Běžné modely tyto vlivy spojují do jedné černé skříňky, čímž ztrácejí expresivitu.

Uživatel přitom potřebuje přesně chápat, zda mu systém doporučuje konkrétní restauraci kvůli jejím vnitřním vlastnostem (výborné hodnocení, sémantická shoda s jeho chutěmi), nebo čistě proto, že se zrovna nachází v bezprostřední blízkosti. Právě nutnost tyto složité motivace rozplést (tzv. *disentanglement*) do srozumitelných pojmů [5] nás přivádí k využití pokročilých metod skrytých reprezentací, které jsou popsány v následující sekci.

1.2 Latentní reprezentace a architektura autoenkodérů

Klasické metody kolaborativního (CF) a obsahového filtrování (CBF) sice dosahují dobrých výsledků, avšak jejich vnitřní (latentní) reprezentace jsou často složité a pro uživatele i vývojáře obtížně interpretovatelné. Moderní přístupy proto stále častěji využívají modely hlubokého učení, zejména rodinu autoenkodérů, jejichž hlavní výhodou je schopnost zachytit i velmi komplexní a nelineární vztahy mezi uživateli a položkami.

1.2.1 Autoenkodéry pro kolaborativní filtrování (CFAE)

Princip těchto modelů spočívá v tom, že se autoenkodér učí komprimovat řídká interakční data do zmenšeného latentního prostoru a následně je z něj s co nejmenší chybou zrekonstruovat. V architektuře CFAE (*Collaborative-Filtering Autoencoders*, zastoupené například modely MultVAE nebo lineární sítí ELSA) je každý uživatel reprezentován vektorem $x_u \in \mathbb{R}^{|I|}$. Enkodér E_c komprimuje tento dlouhý a řídký vektor do hustého (*dense*) latentního prostoru o nízké dimenzionalitě d:

$$y_u = E_c(x_u) = \sigma(W_{enc}x_u + b_{enc}) \tag{1.1}$$

Dekodér D_c se následně snaží tento zkomprimovaný vektor y_u zrekonstruovat a predikovat skóre pro chybějící položky jako $\hat{x}_u = D_c(y_u)$.

Přestože tyto modely nabízejí vynikající prediktivní přesnost, jejich interpretace je obtížná. Vytvářejí totiž tzv. propletené (*entangled*) reprezentace, kde jedna dimenze ovlivňuje mnoho zcela nesouvisejících vlastností položky (např. zároveň žánr restaurace i její lokaci). To z těchto modelů dělá neprůhledné černé skříňky (*black-boxes*) [1]. Vzhledem k potřebě vysvětlitelnosti v doméně lokačních dat je proto nutné tyto reprezentace dodatečně rozplést.

1.2.2 Řídké autoenkodéry (SAE)

Problém černých skříněk a propletených vektorů lze řešit architekturou řídkých autoenkodérů (*Sparse Autoencoders*, SAE). Ty představují funkční rozšíření klasických autoenkodérů, které do trénovacího procesu uměle zavádí přísný požadavek na řídkost (*sparsity*) v latentní vrstvě. Na rozdíl od běžného autoenkodéru se SAE snaží omezit počet současně aktivních neuronů. Toho lze dosáhnout například aktivační funkcí ReLU v kombinaci s $L1$ regularizací, nebo použitím mechanismu *Top-K* výběru, který propustí pouze K nejsilnějších signálů. Tímto omezením se model učí kompaktnější a sémanticky smysluplnější reprezentace, a vyhýbá se tak pouhému zapamatování si dat.

Z matematického hlediska přebírá modul SAE onen hustý a neprůhledný vektor $y_u \in \mathbb{R}^d$ ze základního modelu CFAE a mapuje ho do podstatně širšího prostoru $\mathbb{R}^k$ (kde $k \gg d$) [1]:

$$z_u = E_s(y_u) = \phi(W_s y_u + b_s) \tag{1.2}$$

V této rovnici tvoří z_u hledanou rozpletenou reprezentaci a funkce ϕ vynucuje požadovanou řídkost. Následná celková ztrátová funkce pro trénování tohoto modulu kombinuje chybu rekonstrukce původního hustého vektoru a penalizaci vynucující řídkost (čímž brání tvorbě příliš hustých reprezentací):

$$\mathcal{L}_{SAE} = \frac{1}{|U|} \sum_{u \in U} \left(||y_u - \hat{y}_u||_2^2 \right) + \lambda ||z_u||_1 \tag{1.3}$$

1.2.3 Interpretace a ovládací prvky (Knobs)

Omezením aktivační kapacity prostřednictvím SAE získává výsledná reprezentace z_u unikátní schopnost – její jednotlivé dimenze začínají odpovídat samostatným a izolovaným významovým faktorům v datech. Jak upozorňuje Wang a kol. [6], klasické modely nedokážou tyto faktory přirozeně oddělit, což silně limituje jejich praktickou využitelnost pro pokročilé uživatelské interakce.

Zavedením řídkosti však autoenkodér začne fungovat jako sémantický filtr, který složitě propletená (entanglovaná) data pomyslně rozčesává do struktury nezávislých vláken významu [1]. Pokud například konkrétní dimenze kóduje „zájem o italskou kuchyni“, je možné ji uživateli takto přímo prezentovat. V odborné literatuře se pro tyto rozpletené rysy vžilo označení *ovládací prvky* či *knobs* [1, 14]. Jejich zásadní výhodou je, že je lze přímo napojit na uživatelské rozhraní. Tím se otevírá cesta k tomu, aby systém nejen dokázal svá doporučení zpětně vysvětlit, ale také aby umožnil samotnému uživateli do procesu aktivně zasahovat.

1.3 Vysvětlitelnost a interaktivní řízení (Steering)

Jakmile je složitý latentní prostor modelu rozpleten do srozumitelných sémantických prvků, lze tyto reprezentace využít k obousměrné komunikaci mezi uživatelem a systémem. Směrem od systému k uživateli slouží k poskytování transparentních vysvětlení, zatímco směrem od uživatele k systému otevírají prostor pro aktivní řízení (steering).

1.3.1 Vysvětlitelnost doporučení a její hodnocení

Vysvětlitelnost (*Explainability*) znamená schopnost modelu srozumitelně sdělit uživateli důvody, proč mu byla konkrétní položka navržena. Využití architektury SAE umožňuje dosáhnout tzv. *model-based* (neboli *white-box*) vysvětlitelnosti, kdy je vysvětlení integrální součástí algoritmu a vychází přímo z jeho vnitřního matematického stavu.

Při využití řídkého autoenkodéru lze totiž celkové skóre doporučení formalizovat zjištěním příspěvků jednotlivých složek řídkého vektoru z_u. Pokud budeme předpokládat, že je dekodér lineární vrstvou V, můžeme predikované skóre $\hat{x}_{u,i}$ pro položku i rozepsat jako sumu příspěvků jednotlivých aktivních neuronů:

$$\hat{x}_{u,i} \approx \sum_{j=1}^{k} (V_i \cdot W_{s,j}^T) z_{u,j} \tag{1.4}$$

Díky této dekompozici dokáže systém uživateli přesně odůvodnit, jaký specifický sémantický rys k finálnímu doporučení přispěl nejvíce [1].

Hodnocení kvality takto vygenerovaných vysvětlení představuje v odborné literatuře komplexní výzvu a rozlišují se při něm dva hlavní směry. Z objektivního hlediska se měří tzv. **fidelity** (věrnost), která matematicky vyjadřuje, nakolik prezentované vysvětlení skutečně odpovídá skutečnému vnitřnímu rozhodovacímu procesu modelu. Druhým, avšak pro praktické nasazení často důležitějším přístupem, jsou **uživatelské studie**. Ty hodnotí vysvětlení z pohledu koncového uživatele a zaměřují se na metriky, jakými jsou vnímaná srozumitelnost, přesvědčivost (persuasiveness) či schopnost budovat důvěru (trust) [**Tintarev2012**]. Vysvětlení totiž nemusí být jen technicky přesné, ale musí především rezonovat s mentálním modelem uživatele.

1.3.2 Steering: Definice a pohledy na ovladatelnost

Pokud uživatel díky vysvětlení pochopí, jak model uvažuje, přirozeně vyžaduje možnost toto uvažování korigovat. Pojem *steering* (řízení či kormidlování) se v literatuře o doporučovacích systémech objevuje stále častěji, avšak nenabývá jediné ustálené definice. V současném výzkumu lze identifikovat tři odlišné pohledy na to, kdo a jakým způsobem doporučování řídí:

1. **Algoritmický steering platforem:** Z pohledu ekonomiky a návrhu platforem (často označováno jako *self-preferencing*) představuje steering situaci, kdy samotný algoritmus vychyluje doporučení ve prospěch určitých

položek na úkor čisté uživatelské preference [**Chen2024**]. Typickým příkladem je, když platforma (např. Amazon) algoritmicky "směruje"uživatele ke svým vlastním produktům místo k relevantnějším produktům třetích stran [**Chen2024**]. Zde je tedy uživatel objektem řízení.

2. **Strategický steering ze strany uživatele:** Zcela opačný extrém definují Colella a kol. [15]. Upozorňují, že uživatelé nejsou pouze pasivními poskytovateli dat, ale inteligentními strategickými aktéry. Pokud například uživatel chce dostávat více doporučení na fantasy filmy, může začít záměrně (a nepravdivě) udělovat vysoká hodnocení položkám, o kterých si myslí, že tento žánr v očích algoritmu posílí. Uživatel tak pomocí falešné zpětné vazby strategicky manipuluje (steeruje) systém, aby dosáhl svého osobního cíle [15].

3. **Explicitní interaktivní řízení (User-controllability):** Prostřední a z hlediska této práce nejrelevantnější přístup chápe steering jako přímou, transparentní a podporovanou funkci uživatelského rozhraní (HCI). Výzkumy jako systém TasteWeights [**Tasteweights2012**] či studie v oblasti e-learningu [4] prokazují, že pokud dáme uživatelům explicitní vizuální nástroje (např. posuvníky) k úpravě vah jejich preferencí, dramaticky to zvyšuje jejich důvěru a pocit kontroly (agency) nad systémem.

V námi uvažované architektuře se steering realizuje právě třetím jmenovaným způsobem, a to přímou modifikací hodnot uživatelského vektoru v latentním prostoru SAE. Nechť uživatel prostřednictvím posuvníku v rozhraní vyjádří záměr posílit svůj zájem o konkrétní sémantický rys (např. „hledám více muzeí“), jemuž odpovídá neuron n. Systém zkonstruuje nový, modifikovaný preferenční vektor z'_u pomocí afinní interpolace:

$$z'_u = \alpha z_u + (1 - \alpha) e_n \tag{1.5}$$

kde $e_n \in \mathbb{R}^k$ je tzv. one-hot vektor s hodnotou 1 na pozici žádaného neuronu n a 0 jinde. Parametr $\alpha \in [1]$ určuje sílu zachování původního profilu. Čím více se α blíží k nule, tím agresivněji systém přepíše uživatelovu historickou stopu ve prospěch nově vyžádané preference. Takto upravený vektor je následně v reálném čase propuštěn skrze dekodér, čímž dojde k okamžité aktualizaci doporučených položek.

1.3.3 Etické, právní a kognitivní aspekty interakce

Poskytnutí takto silné ovladatelnosti otevírá důležité otázky z oblasti psychologie rozhodování. Zviditelnění dopadů řízení (steeringu) pomáhá předcházet tzv. nadměrnému či nedostatečnému spoléhání se na systém (*over- and under-reliance*) [**Tintarev2012**]. Uživatel, který vidí, z čeho doporučení vychází, a může ho upravit, dokáže snáze ignorovat irelevantní návrhy. Na straně druhé může přílišná kontrola vést k nežádoucí akceleraci tvorby informačních bublin (*filter bubbles*). Jakmile si uživatel systém extrémně přizpůsobí pouze svým aktuálním a ověřeným zájmům, ztrácí se prvek objevování nového a nečekaného obsahu (tzv. *serendipity*).

Kromě kognitivních aspektů je však nutné zohlednit i širší **etické implikace**. Jak upozorňují studie zaměřené na férovost (*fairness*) v doporučovacích systémech

[16], algoritmy mohou snadno zrcadlit či dokonce zesilovat strukturální předsudky a tzv. *popularity bias* (neúměrné upřednostňování již populárních položek na úkor těch méně známých). Další etický problém nastává, pokud má poskytovatel platformy duální roli – tedy funguje jako informační zprostředkovatel i jako přímý prodejce. V takových případech může docházet k netransparentnímu algoritmickému steeringu ze strany platformy (tzv. *self-preferencing*), kdy systém skrytě směruje uživatele k vlastním či ziskovějším položkám [**Chen2024**]. Transparentní a uživatelem explicitně ovladatelný profil tak představuje silný nástroj, jak tuto informační asymetrii a riziko algoritmické manipulace omezit.

Tyto etické a psychologické výzvy se navíc v posledních letech promítají přímo do **legislativní roviny**. V kontextu Evropské unie zavedlo Obecné nařízení o ochraně osobních údajů (GDPR) přísnější požadavky na transparentnost automatizovaného rozhodování, které se v odborné literatuře o umělé inteligenci často interpretují jako tzv. *právo na vysvětlení* (right to explanation) [17, 18]. Od systémů, které významně ovlivňují uživatelské chování a pracují s osobními preferencemi, se tak dnes již nevyžaduje pouze vysoká prediktivní přesnost, ale i právně podložená schopnost svá rozhodnutí srozumitelně zdůvodnit. Návrh moderních interaktivních doporučovacích systémů by proto měl vždy balancovat mezi uspokojením přesných uživatelských požadavků, zachováním dostatečné rozmanitosti a dodržováním oborových i právních standardů transparentnosti.

1.4 Shrnutí

Tato kapitola položila teoretické a formální základy pro návrh vysvětlitelného a ovladatelného doporučovacího systému. V první části jsme představili klasické přístupy k doporučování a zasadili je do specifického kontextu bodů zájmu (POI). Ukázalo se, že v této doméně, kde každé doporučení vyžaduje fyzickou a časovou investici uživatele, je transparentnost systému a schopnost rozplést složité lokační motivace naprosto klíčová.

Následně jsme detailně popsali přechod od řídkých matic interakcí k latentním reprezentacím pomocí hlubokého učení. Zatímco moderní autoenkodéry pro kolaborativní filtrování (CFAE) dosahují špičkové prediktivní přesnosti, vytvářejí neprůhledné, tzv. propletené černé skříňky. Bylo formálně ukázáno, jak architektura řídkých autoenkodérů (SAE) tvoří funkční most mezi těmito přesnými modely a požadavkem na srozumitelnost. Vynucením řídkosti dokáže SAE tyto nesrozumitelné vektory převést na izolované, monosémantické rysy – tzv. ovládací prvky (knobs).

V poslední části jsme vysvětlili, že jakmile je latentní prostor takto rozpleten, otevírá se cesta k pokročilé obousměrné interakci. Směrem k uživateli umožňuje systém generovat exaktní a věrná vysvětlení přímo na základě vnitřního stavu sítě (*model-based explainability*), zatímco směrem k systému poskytuje uživateli možnost aktivně a v reálném čase řídit svůj profil (steering). Byla přitom zdůrazněna i nutnost brát v potaz psychologické a kognitivní aspekty, jako je budování důvěry na jedné straně a riziko vzniku informačních bublin na straně druhé.

Z tohoto teoretického ukotvení budeme pevně vycházet v následujících částech práce. Zatímco následující kapitola kriticky zmapuje, jakým způsobem k těmto jednotlivým výzvám dosud přistupovala a přistupuje světová odborná literatura, třetí kapitola tyto poznatky následně přetaví do samotného architektonického

návrhu našeho řešení.

2 Související práce

Tato kapitola představuje rešerši současného stavu poznání v oblastech, které se dotýkají zaměření této diplomové práce. Postupně jsou představeny existující přístupy k vysvětlitelnosti doporučovacích systémů, metody pro rozpletení latentních reprezentací (disentanglement), interaktivní a ovladatelné systémy a specifika doporučování v doméně bodů zájmu (POI). Následně je diskutován aktuální trend zapojení velkých jazykových modelů (LLM). V závěru kapitoly jsou tyto proudy syntetizovány a je identifikována výzkumná mezera, kterou se tato práce snaží zaplnit.

2.1 Explainable recommendation systems

Výzkum v oblasti vysvětlitelných doporučovacích systémů (Explainable Recommendation Systems, XAI-Rec) zaznamenal v posledních letech značný nárůst, což dokládají rozsáhlé přehledové studie [19, 2]. Cílem těchto systémů je nejen poskytnout uživateli relevantní položku, ale také srozumitelně objasnit důvody, které k tomuto doporučení vedly. V literatuře se tyto přístupy zpravidla dělí do dvou hlavních kategorií: modely se zabudovanou vysvětlitelností (model-based) a metody aplikované dodatečně (post-hoc) [20].

2.1.1 Model-based explainability

Model-based (často označované jako „white-box“) přístupy začleňují mechanismus vysvětlování přímo do architektury doporučovacího algoritmu [19]. Tyto systémy jsou z podstaty transparentní, neboť cesta od vstupu k predikci je přímo sledovatelná. Příkladem jsou modely využívající mechanismy pozornosti (attention mechanisms), které se dokážou zaměřit na specifické vlastnosti nebo části uživatelských recenzí a na jejich základě konstruovat jak predikci, tak samotné vysvětlení [2]. Nevýhodou těchto systémů však může být jejich vyšší výpočetní náročnost a někdy nižší prediktivní přesnost oproti vysoce komplexním „black-box“ modelům.

2.1.2 Post-hoc explainability

Post-hoc vysvětlitelnost zachovává stávající (často neprůhledné) doporučovací modely typu „black-box“ v jejich původní podobě a mechanismus vysvětlování nad nimi buduje jako oddělenou vrstvu [20]. Tyto modely typicky analyzují vstupy a výstupy algoritmu a zpětně odhadují příčiny doporučení.

V kontextu lokačních dat je významným zástupcem tohoto přístupu model ReEL (*Review-Aware Explanation of Location Recommendation*) [7]. Tento systém extrahuje z textových recenzí uživatelů konkrétní aspekty (např. kvalita jídla, obsluha, cena) a jejich sentiment. Následně formuje uživatelské preference jako bipartitní graf (uživatel-aspekt a místo-aspekt) a pomocí dolování hustých podgrafů dokáže vygenerovat doporučení doprovázené vysvětlením, které reflektuje specifické priority daného uživatele [7].

2.2 Disentangled representations

Tradiční modely založené na hlubokém učení sice dosahují vysoké přesnosti, ale vytvářejí husté a propletené (*entangled*) reprezentace, ve kterých jedna dimenze vektoru ovlivňuje mnoho nesouvisejících vlastností položky. K řešení tohoto problému slouží metody, které tvoří tzv. rozpletené reprezentace (*disentangled representations*).

2.2.1 VAE a další přístupy

Významnou rodinu modelů pro kolaborativní filtrování tvoří autoenkodéry. Modely jako MultVAE [1] využívají variační autoenkodéry k modelování komplexních distribucí dat přes pravděpodobnostní latentní prostor. Oblíbené jsou rovněž lineární autoenkodéry, reprezentované například modelem ELSA (*Scalable Linear Shallow Autoencoder*) [1]. Modely jako ELSA poskytují velmi konkurenceschopný výkon a škálovatelnost, přestože jsou jejich husté vnitřní vrstvy stále obtížně interpretovatelné z pohledu koncového uživatele.

2.2.2 From Knots to Knobs a řídké autoenkodéry

Zásadní posun v interpretovatelnosti kolaborativního filtrování přinesl přístup představený v práci *From Knots to Knobs* [6], který se zaměřuje na rozpletení latentních prostorů na sémanticky nezávislé koncepty. Jak ve svém nedávném výzkumu ukazují Spišák et al. [1], implementace řídkých autoenkodérů (SAE) do procesu kolaborativního filtrování dokáže nečitelné vnitřní stavy rozplést na samostatné monosémantické rysy. Tyto sémanticky čisté komponenty se mohou přímo mapovat na známé tagy či metadata, čímž vznikají transparentní ovládací prvky (tzv. *knobs*), které mohou uživatelé pochopit a modifikovat [6].

2.2.3 Sémantické mapování pomocí LLM (Autointerpretability)

Zatímco tradiční modely vyžadují pro mapování vnitřních stavů statistické metody nad metadaty (např. TF-IDF), moderní výzkum v oblasti mechanistické interpretability začíná k tzv. auto-interpretaci neuronů využívat velké jazykové modely (LLM) [21]. LLM dokáže analyzovat texty či položky spojené s nejsilnějšími aktivacemi konkrétního neuronu a na základě svých znalostí vyvodit zastřešující sémantický koncept [14]. Integrace LLM tak představuje vysoce efektivní způsob, jak extrahovaným řídkým rysům přiřadit lidsky srozumitelné štítky.

2.3 Interaktivní a ovladatelné recommender systémy

Možnost uživatele aktivně zasahovat do doporučovacího procesu je klíčová pro zvýšení důvěry v systém a celkovou spokojenost. Interaktivní a ovladatelné systémy (tzv. *steerable systems*) poskytují uživatelům nástroje k úpravě jejich profilů v reálném čase [4].

2.3.1 TasteWeights a příbuzné koncepty

Typickým zástupcem vizuálně interaktivního hybridního systému je TasteWeights [8]. Tento systém umožňuje uživatelům na úrovni grafického rozhraní dynamicky upravovat váhy různých preferencí (např. interpretů nebo žánrů) a okamžitě sledovat dopad těchto změn na finální seznam doporučení [8]. Zviditelnění vlivu uživatelské kontroly napomáhá uživatelům lépe pochopit logiku na pozadí a zvyšuje jejich ochotu systém používat [4].

2.3.2 User-controllable personalization

Vedle interakce s konkrétními položkami se objevují i přístupy umožňující ovládat přímo zdroje doporučení. Příkladem je práce Parry a Brusilovskyho zaměřená na uživatelsky řízenou personalizaci pomocí systému SetFusion [22]. V tomto případě uživatelé pomocí sady ovládacích prvků přímo regulují, nakolik má systém čerpat z kolaborativního filtrování, z obsahové analýzy či jiných zdrojů. Tento explicitní způsob kontroly posiluje uživatelskou autonomii a redukuje frustraci z nežádoucích či nepřesných doporučení.

2.4 Doporučování POI

Doporučování bodů zájmu (POI – *Points of Interest*) je specifickou podoblastí, která se liší silnou závislostí na prostorovém a časovém kontextu (např. vzdálenost mezi lokacemi, denní doba) [5].

2.4.1 Časoprostorové a sekvenční modely

Moderní přístupy pro tzv. *Next POI Recommendation* (doporučování dalšího bodu zájmu) využívají sofistikované metody hlubokého učení, včetně rekurentních neuronových sítí (RNN) nebo grafových sítí (GNN) k extrakci prostorově-časových vzorců [5]. Většina těchto hybridních metod je však orientována primárně na zlepšení objektivních metrik a uživateli nenabízí srozumitelná vysvětlení ani mechanismy pro přímé interaktivní řízení svých časoprostorových preferencí.

2.4.2 Řešení sémantické řídkosti pomocí LLM (Pseudo-profily)

Zásadním problémem v doméně POI je, že často chybí bohaté textové recenze nebo detailní sémantické popisy míst, z nichž by bylo možné snadno generovat interpretovatelná vysvětlení. Pokusem o řešení tohoto problému jsou nedávné přístupy jako model *CrossDR-Gen* [5], které zkoumají rozpletené reprezentace napříč geografickými a časovými faktory za pomoci LLM.

V situacích s nedostatkem explicitních dat o uživateli využívají LLM k těžbě tzv. pseudo-profilů. Na základě historie navštívených kategorií míst dokáže LLM logicky vyvodit zájmy a osobnost uživatele [5]. Takto obohacené profily pak slouží nejen ke zpřesnění doporučování, ale zároveň umožňují generování kvalitních a vysoce personalizovaných vysvětlení v přirozeném jazyce, což přímo posiluje transparentnost celého procesu [23].

2.5 Shrnutí

Z provedené rešerše literatury vyplývá, že ačkoliv jednotlivé oblasti zažívají rychlý vývoj, existuje zřejmá výzkumná mezera na jejich pomezí. Na jedné straně interaktivní systémy jako TasteWeights umožňují uživatelům měnit své preference a modely jako ReEL přinášejí vysvětlení pro doménu POI. Na straně druhé, moderní metody využívající řídké autoenkodéry (SAE) pro tvorbu rozpletených reprezentací a jejich interpretaci pomocí LLM jsou primárně zkoumány v tradičním kolaborativním filtrování, zpracování přirozeného jazyka nebo e-commerce.

Navzdory těmto pokrokům **zatím nebyl dostatečně prozkoumán přístup, který by propojoval inherentní rozpletení latentních reprezentací pomocí SAE, plynulé interaktivní uživatelské ovládání (steering) a sémantickou syntézu pomocí LLM přímo v kontextu specifik doporučování volnočasových aktivit (POI)**. Předkládaná diplomová práce se proto zaměřuje přesně na průnik těchto oblastí a navrhuje architekturu, která z neprůhledných latentních modelů vytvoří systém plně transparentní a řiditelný samotným uživatelem.

3 Návrh řešení

Tato kapitola detailně představuje návrh vysvětlitelného a ovladatelného doporučovacího systému pro doménu volnočasových aktivit (POI). Vychází z teoretických poznatků a existujících přístupů popsaných v předchozích kapitolách. Nejprve jsou definovány hlavní cíle a výzkumné otázky práce. Následně je matematicky formalizována celková architektura systému, která kombinuje modely kolaborativního filtrování s řídkými autoenkodéry (SAE). Závěr kapitoly se věnuje způsobům, jakými model generuje vysvětlení a jak umožňuje uživatelům interaktivně upravovat jejich preferenční profily.

3.1 Cíle a výzkumné otázky

Hlavním cílem navrženého řešení je překonat inherentní neprůhlednost tradičních modelů kolaborativního filtrování a vytvořit systém, který nejen přesně doporučuje body zájmu (POI), ale zároveň dokáže své vnitřní stavy srozumitelně interpretovat a poskytnout uživateli nástroje pro jejich přímou úpravu. Pro dosažení tohoto cíle byly stanoveny následující výzkumné otázky (Research Questions, RQ):

- **RQ1:** Jak efektivně transformovat husté, propletené (*entangled*) latentní reprezentace uživatelů do řídkých a monosémantických rysů bez výrazné ztráty prediktivní přesnosti?
- **RQ2:** Jakým způsobem lze tyto abstraktní řídké faktory automaticky mapovat na sémanticky pochopitelné tagy a kategorie míst?
- **RQ3:** Jak matematicky modelovat a v uživatelském rozhraní implementovat zásah uživatele (*steering*) do jeho profilu tak, aby systém okamžitě a konzistentně přepočítal doporučení?

3.2 Architektura navrženého systému

Navržená architektura využívá tzv. vnořený autoenkodér (*nested autoencoder*). Nechť $\mathcal{U}$ je množina uživatelů, $\mathcal{I}$ množina položek (POI) a $\mathbf{X} \in \mathbb{R}^{|\mathcal{U}|\times|\mathcal{I}|}$ je matice uživatelských interakcí. Vstupem modelu pro konkrétního uživatele $u \in \mathcal{U}$ je vektor jeho interakcí $\mathbf{x}_u \in \mathbb{R}^{|\mathcal{I}|}$.

Celá architektura se skládá ze dvou hlavních modulů: základního modelu kolaborativního filtrování (CFAE) a řídkého autoenkodéru (SAE) [6].

3.2.1 Modelování kolaborativního filtrování (CFAE)

Základní model (např. ELSA nebo MultVAE) se skládá z enkodéru E_c a dekodéru D_c. Enkodér E_c mapuje řídký vektor interakcí $\mathbf{x}_u$ do hustého, nízkodimenzionálního latentního prostoru $\mathbb{R}^d$:

$$\mathbf{y}_u = E_c(\mathbf{x}_u) \tag{3.1}$$

kde $\mathbf{y}_u \in \mathbb{R}^d$ představuje tradiční, avšak sémanticky neprůhlednou (*entangled*) reprezentaci uživatele. Standardní model by tuto reprezentaci rovnou dekódoval pro získání predikcí $\hat{\mathbf{x}}_u = D_c(\mathbf{y}_u)$. Abychom však získali interpretovatelné dimenze, vkládáme do architektury SAE.

3.2.2 Sparse autoencoder pro interpretovatelné preference

Řídký autoenkodér (SAE) přijímá jako vstup hustý vektor $\mathbf{y}_u$ a mapuje jej do podstatně širšího prostoru $\mathbb{R}^k$ ($k \gg d$), přičemž vynucuje, aby většina komponent vektoru byla nulová. SAE je definován vlastním enkodérem E_s a dekodérem D_s:

$$\mathbf{z}_u = \phi(\mathbf{W}_{enc}\mathbf{y}_u + \mathbf{b}_{enc}) \tag{3.2}$$

kde $\mathbf{W}_{enc} \in \mathbb{R}^{k \times d}$ a $\mathbf{b}_{enc} \in \mathbb{R}^k$ jsou váhy a bias enkodéru SAE, a ϕ představuje aktivační funkci vynucující řídkost. V závislosti na zvolené variantě SAE může jít o ReLU v kombinaci s L_1 regularizací, nebo o funkci Top-K, která ponechá nenulových pouze K neuronů s nejvyšší aktivací [1].

Vektor $\mathbf{z}_u \in \mathbb{R}^k$ tvoří tzv. *rozpletenou reprezentaci* profilu. Každý nenulový prvek (neuron) tohoto vektoru (tzv. *knob*) kóduje jednu izolovanou sémantickou vlastnost [6]. Následná rekonstrukce původního hustého vektoru probíhá pomocí dekodéru SAE:

$$\hat{\mathbf{y}}_u = \mathbf{W}_{dec}\mathbf{z}_u + \mathbf{b}_{dec} \tag{3.3}$$

Trénování vnořeného SAE modulu minimalizuje chybu rekonstrukce hustého vektoru doplněnou o penalizaci řídkosti:

$$\mathcal{L}_{SAE} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} ||\mathbf{y}_u - \hat{\mathbf{y}}_u||_2^2 + \lambda ||\mathbf{z}_u||_1 \tag{3.4}$$

Alternativně, v případě modelů optimalizovaných na kosinovou podobnost (např. ELSA), lze L2 ztrátu nahradit maximalizací $\cos(\mathbf{y}_u, \hat{\mathbf{y}}_u)$ [1]. Predikce finálních skóre pro doporučení je následně získána aplikací původního CFAE dekodéru na zrekonstruovaný vektor: $\hat{\mathbf{x}}_u = D_c(\hat{\mathbf{y}}_u)$.

3.3 Vysvětlitelnost modelu

Extrahovaný řídký vektor $\mathbf{z}_u$ tvoří matematický základ pro vysvětlitelnost, nicméně jednotlivým dimenzím (neuronům) je nutné přiřadit lidsky srozumitelný význam.

3.3.1 Sémantické mapování (Labeling) řídkých faktorů

Pro pojmenování faktorů (*labeling*) využijeme matici metadat položek (POI). Nechť $\mathcal{T}$ je množina všech dostupných tagů a kategorií (např. *historie*, *park*, *kavárna*). Každý neuron v prostoru $\mathbb{R}^k$ se aktivuje pro specifickou podmnožinu bodů zájmu. Hodnotíme korelaci (nebo TF-IDF skóre) mezi aktivacemi daného neuronu a výskytem konkrétního tagu $t \in \mathcal{T}$ u těchto položek.

S využitím informační teorie [6] můžeme mapování formalizovat pomocí zhodnocení entropie H a Kullback-Leiblerovy divergence (D_{KL}). Tag, který vykazuje nejvyšší D_{KL} vůči průměrnému rozdělení aktivací a zároveň dostatečně

nízkou entropii (je vysoce specifický), je přiřazen k danému neuronu. Každý "knob"$n \in \{1, \ldots, k\}$ tak získá svou sémantickou textovou reprezentaci (např. $label(n) =$ „Italská kuchyně“).

3.3.2 Generování vysvětlení

Systém u každé navrhované položky identifikuje, které neurony n ze zredukované množiny (kde $\mathbf{z}_{u,n} > 0$) přispěly největší měrou k finálnímu predikčnímu skóre $\hat{\mathbf{x}}_{u,i}$. Uživatel tak vidí důvody vyjádřené tagy odpovídajícími nejvíce aktivním sémantickým dimenzím (např. *„Tato lokace vám byla doporučena na základě vaší afinity k vlastnostem [Park] a [Klidné prostředí]“*).

3.4 Ovládání a úprava preferencí (Steering)

Možnost řízení doporučení je implementována formou přímé manipulace s hodnotami vektoru $\mathbf{z}_u$ v latentním prostoru, inspirováno přístupem navrženým v [6].

3.4.1 Matematický model steeringu

V uživatelském rozhraní má uživatel k dispozici posuvníky představující sémanticky pojmenované neurony, s nimiž může interagovat. Nechť $\mathbf{z}_u$ představuje aktuální, na jednotkovou sumu normalizovanou, řídkou reprezentaci uživatele (jeho profil). Pokud uživatel vyjádří záměr posílit zájem o konkrétní tag t odpovídající neuronu n, zkonstruujeme modifikovaný preferenční vektor $\mathbf{z}'_u$ pomocí interpolace:

$$\mathbf{z}'_u = \alpha \mathbf{z}_u + (1 - \alpha)\beta_n \tag{3.5}$$

kde $\beta_n \in \mathbb{R}^k$ je tzv. *one-hot* kódovaný vektor, který má na pozici neuronu n hodnotu 1 a všude jinde 0. Parametr $\alpha \in [1]$ vyjadřuje sílu původního profilu vůči nově vynucené preferenci. Například pro $\alpha = 0.8$ si uživatel zachová většinu svých původních zvyklostí, ale systém významně dodatečně penalizuje či odměňuje položky související s vybraným aspektem [6].

3.4.2 Aktualizace doporučení

Tento modifikovaný řídký vektor $\mathbf{z}'_u$ je následně bez nutnosti přetrénování modelu rovnou propuštěn skrz dekodéry:

$$\hat{\mathbf{x}}'_u = D_c(\mathbf{W}_{dec}\mathbf{z}'_u + \mathbf{b}_{dec}) \tag{3.6}$$

Tím dojde k dynamickému a výpočetně velmi levnému přepočítání doporučovacích skóre pro všechny body zájmu. Výsledkem je nový seznam POI s aktualizovaným pořadím, který okamžitě vizuálně reflektuje uživatelův řídící záměr.

3.5 Očekávané přínosy

Zavedením rigorózního oddělení kolaborativních signálů (v $\mathbf{y}_u$) od sémantických dimenzí (v $\mathbf{z}_u$) bude dosaženo architektonické modularity. Model nejenže překlene

propast mezi přesnými *black-box* přístupy a pochopitelnými heuristikami, ale díky formálně definovanému mechanismu *steeringu* umožní provádět *what-if* scénáře v latentním prostoru v reálném čase.

4 Implementace [draft]

Tato kapitola popisuje praktickou realizaci navrženého doporučovacího systému. Postupně představíme využité nástroje, datovou sadu a způsob jejího předzpracování. Následně rozebereme implementaci samotného offline modelu, logiku vysvětlovacího modulu a nakonec i podobu uživatelského rozhraní, které slouží pro interakci se systémem.

4.1 Použité technologie a knihovny

Celý projekt je programován v jazyce Python. Pro práci s daty a maticovými operacemi jsme využili standardní knihovny Pandas a NumPy. Samotná architektura modelů kolaborativního filtrování (CFAE) a řídkých autoenkodérů (SAE) je postavena na frameworku PyTorch, který umožňuje efektivní trénování na grafických kartách (GPU).

Pro automatizované pojmenování neuronů a tvorbu textových vysvětlení bylo nutné zvolit vhodný velký jazykový model (LLM). Zatímco dřívější výzkumy pro tyto účely často spoléhaly na výpočetně nejtěžší modely, jakými byly ve své době například GPT-3.5-turbo či Claude 2 [5], nedávné studie prokázaly, že pro úlohy sémantické interpretace a evaluace lze úspěšně využít odlehčené (tzv. *lightweight*) modely [14, 24]. V rámci inženýrského návrhu jsme proto zvažovali tři hlavní přístupy s ohledem na potřeby a limity akademického prostředí:

- **Placené API služby (např. OpenAI GPT-4o-mini):** Tento přístup představuje současný průmyslový standard s vysokou spolehlivostí formátování (např. JSON). Cenově se jedná o velmi efektivní řešení s náklady 0,15 USD za milion vstupních a 0,60 USD za milion výstupních tokenů [25], pro rozsáhlé experimenty nicméně stále vyžaduje vyhrazený finanční rozpočet.

- **Lokální open-weights modely (např. rodina Gemma 3 nebo Llama 3):** Tyto modely lze stáhnout a provozovat zcela offline [26, 24]. Jejich hlavní výhodou je nulová cena za API a absolutní ochrana soukromí uživatelských dat. Tento přístup však nebyl zvolen z důvodu vysokých nároků na paměť a výpočetní výkon lokálních grafických karet.

- **Bezplatné úrovně (Free Tier) komerčních API:** Vývojářské platformy jako Google AI Studio poskytují pro vybrané modely (např. rychlý model Gemini 2.5 Flash-Lite) velkorysý bezplatný přístupový tarif [26]. Daní za využití této úrovně je skutečnost, že poskytovatel může odeslaná data využívat pro zlepšování svých vlastních produktů, což je ovšem pro akademické experimenty s již veřejnými daty obvykle přijatelný kompromis.

Na základě tohoto srovnání a pilotního testování jsme se pro napojení naší implementace rozhodli využít právě bezplatný tarif platformy **Google AI Studio s modelem řady Gemini**. Toto řešení zcela eliminuje finanční náklady na zpracování a anotaci tisíců neuronů ze SAE. Zmíněný kompromis v podobě sběru dat ze strany poskytovatele je v kontextu této práce akceptovatelný, jelikož

pracujeme s veřejně dostupným datasetem recenzí z platformy Yelp a nedochází tak k žádnému narušení soukromí reálných uživatelů.

Samotné uživatelské rozhraní a webová aplikace pro následnou uživatelskou studii [draft: pak běží nad frameworkem Streamlit. Tato knihovna v jazyce Python byla zvolena proto, že umožňuje rychlé a efektivní vytvoření interaktivních ovládacích prvků (jako jsou posuvníky pro mechanismus *steeringu*) a jejich přímé napojení na backendové výpočty modelu. Výrazně tak urychluje vývoj iterativních prototypů bez nutnosti psát složitý front-endový kód v jazyce JavaScript.]

4.2 Předzpracování a reprezentace dat

K trénování a testování systému jsme zvolili veřejně dostupný dataset Yelp. Obsahuje velké množství interakcí (recenzí) mezi uživateli a body zájmu (POI), a především bohatá metadata potřebná pro pozdější vysvětlování.

Data bylo nutné nejprve vyčistit. Odstranili jsme neaktivní uživatele a lokace s malým počtem hodnocení pomocí tzv. K-core filtrování (pro $K = 5$). [PŘÍPADNĚ: V případech, kdy byla data pro určité scénáře příliš řídká, jsme provedli syntetická doplnění uživatelských profilů, abychom simulovali konzistentnější historii návštěv.]

Z původních dat jsme extrahovali a zpracovali následující atributy:

- **Geolokace:** Souřadnice jednotlivých míst (zeměpisná šířka a délka).
- **Kategorizace a tagy:** Každé místo v datasetu Yelp má přiřazenou sadu kategorií (např. *Cafe, Mexican, Gym*). Tyto kategorie jsme převedli do textové podoby a využili je jako základní slovník pro sémantické mapování neuronů.
- **Interakce:** Samotná hodnocení (hvězdičky) jsme pro účely základního modelu převedli na implicitní zpětnou vazbu, kde hodnota 1 značí, že uživatel dané místo navštívil a ohodnotil alespoň 3 hvězdičkami.

Po předzpracování obsahuje dataset [DOPLŇ ČÍSLO] uživatelů, [DOPLŇ ČÍSLO] bodů zájmu a [DOPLŇ ČÍSLO] interakcí.

4.3 Implementace modelu

Základní doporučovací algoritmus se skládá ze dvou částí, které trénujeme postupně. Jako první jsme naimplementovali základní model kolaborativního filtrování. [ZDE KRÁTCE POPIŠ, JESTLI POUŽÍVÁŠ ELSA NEBO NĚCO JINÉHO]. Tento model analyzuje implicitní interakce a každému uživateli přiřadí hustý (dense) vektor v latentním prostoru. Model byl optimalizován pomocí [DOPLŇ LOSS FUNKCI, např. binární křížové entropie].

Na výstup tohoto modelu jsme následně napojili vrstvu řídkého autoenkodéru (SAE). Abychom dosáhli požadované rozpletenosti (disentanglement) a vynutili aktivaci jen několika málo neuronů současně, použili jsme aktivační funkci Top-K. Ta při dopředném průchodu ponechá nenulových pouze K neuronů s nejvyšší hodnotou a zbytek vynuluje. Během experimentů jsme testovali různé konfigurace a velikosti latentního prostoru. Ve finální verzi model pracuje s [DOPLŇ VELIKOST, např. 2048] dimenzemi a hodnotou K nastavenou na [DOPLŇ ČÍSLO].

[DOPLŇ VIZUALIZACI]

4.4 Systém vysvětlování a úprav

Aby byl model srozumitelný, museli jsme vyřešit překlad mezi natrénovanými číselnými hodnotami v SAE a textem. O to se stará vysvětlovací a řídící (Explain/Steer) modul.

Pro mapování neuronů na lidsky pochopitelné pojmy jsme využili jazykový model (LLM). Systém pro každý aktivní neuron vyhledá lokace, které ho nejvíce stimulují, a jejich metadata (kategorie a tagy) pošle jako prompt do LLM. Jazykový model z těchto dat vyvodí společný jmenovatel a vygeneruje pro daný neuron krátký popisný štítek (např. *„Klidná místa pro práci“*). Stejný modul se pak podílí i na generování celkových textových vysvětlení k výsledným doporučením, kdy spojuje aktivní štítky uživatele s vlastnostmi doporučeného místa.

Součástí tohoto modulu je také backendová logika pro interakci (steering). Pokud uživatel vyjádří požadavek na změnu preferencí, modul vezme jeho aktuální řídký vektor a provede interpolaci s vektorem upravovaného neuronu. Takto modifikovaný profil následně pošle zpět do dekodéru, který bez nutnosti přetrénování bleskově vrátí nová doporučovací skóre.

4.5 Uživatelské rozhraní

Celá výše popsaná logika je zabalena do webové aplikace, se kterou pracují účastníci uživatelské studie. Rozhraní záměrně skrývá veškerou matematickou složitost modelu a prezentuje data vizuálně.

V levém panelu uživatel vidí svůj vygenerovaný profil. Ten je reprezentován sadou posuvníků, které odpovídají aktivním neuronům s přiřazenými štítky z LLM. Uživateli se po načtení stránky zobrazí úvodní seznam doporučených bodů zájmu. U každého doporučení je kromě názvu a kategorie uvedeno také krátké vysvětlení, proč systém dané místo vybral.

Hlavním prvkem rozhraní je možnost s posuvníky volně manipulovat. Jakýkoliv posun vyvolá požadavek na backend, systém přepočítá doporučení podle nové váhy faktorů a aktualizuje seznam míst na obrazovce. Tento okamžitý vizuální dopad (feedback loop) uživateli jasně ukazuje, že má nad algoritmem kontrolu.

Seznam použitých zkratek

AI (Artificial Intelligence): umělá inteligence

API (Application Programming Interface): rozhraní pro programování aplikací

CBF (Content-Based Filtering): obsahové filtrování

CF (Collaborative Filtering): kolaborativní filtrování

CFAE (Collaborative Filtering Autoencoder): autoenkodér pro kolaborativní filtrování

GPU (Graphics Processing Unit): grafická procesorová jednotka

HCI (Human-Computer Interaction): interakce člověka s počítačem

JSON (JavaScript Object Notation): textový formát pro výměnu strukturovaných dat

LLM (Large Language Model): velký jazykový model

NDCG (Normalized Discounted Cumulative Gain): normalizovaný diskontovaný kumulativní zisk

POI (Point of Interest): bod zájmu (např. restaurace, památka, apod.)

RS (Recommender System): doporučovací systém

SAE (Sparse Autoencoder): řídký autoenkodér

TF-IDF (Term Frequency – Inverse Document Frequency): frekvence slova vůči inverzní frekvenci dokumentu

UI (User Interface): uživatelské rozhraní

VAE (Variational Autoencoder): variační autoenkodér

XAI (Explainable Artificial Intelligence): vysvětlitelná umělá inteligence

A Přílohy

A.1 První příloha